Au cœur du sujet, au bord de la ligne :
Divergence éditoriale et tonalité dans la presse française

BARRET Mélanie, PRADEL--FERNANDES Nycia et REBOURS Léna
Université PSL, Paris

1. Introduction

La presse d'information occupe une place centrale dans la structuration de l'espace public : en sélectionnant certains sujets, en hiérarchisant les faits et en privilégiant des angles spécifiques, les médias contribuent à définir « ce dont on parle », dit "agenda-setting" (McCombs & Shaw, 1972) et « comment on en parle », dit "framing" (Entman, 1993). Dans un environnement informationnel marqué par l'abondance de contenus, la segmentation des audiences et la spécialisation croissante des titres, ces mécanismes prennent une dimension particulièrement saillante : un même événement peut être traité de façon sensiblement différente selon qu'il relève d'une presse généraliste, économique, professionnelle, magazine ou de pure players numériques, chacune de ces familles mobilisant des routines, priorités et cadrages propres.

Dans ce contexte, les approches de *computational social science* offrent des outils robustes pour objectiver, à grande échelle, les régularités thématiques et discursives des productions médiatiques. Parmi elles, la modélisation de topics (*topic modeling*) s'est imposée comme une méthode de référence pour explorer des corpus journalistiques, identifier des thématiques latentes et mesurer leur saillance au niveau des documents (Blei et al., 2003; Korencic et al., 2015).

Toutefois, un aspect peu exploré revient dans les travaux appliquant le topic modeling aux médias. La plupart des analyses se concentrent sur les différences *entre* médias ou *entre* catégories, sans quantifier systématiquement les écarts *au sein* d'une même famille éditoriale : autrement dit, dans quelle mesure un article « s'éloigne » du profil thématique typique de son groupe, et quelles conséquences discursives cela peut avoir.

Ce projet propose une démarche intégrée pour répondre à ces deux enjeux, sur un corpus de 5 821 articles de presse publicitaire en français, réassignés à cinq grandes catégories éditoriales (presse spécialisée/professionnelle, économique/financière, généraliste, numérique/pure players, magazine). À partir des textes complets, nous (1) extrayons des topics globaux du corpus, puis (2) caractérisons la signature thématique moyenne de chaque catégorie, et (3) mesurons pour chaque article un degré d'écart à cette signature. Enfin, (4) nous étudions le lien entre cet écart thématique et la tonalité affective des articles, estimée par analyse de sentiment avec un modèle de type CamemBERT.

À partir des cadres de l'*agenda-setting* et du *framing* (McCombs & Shaw, 1972; Entman, 1993), qui décrivent respectivement la sélection et la hiérarchisation des enjeux et la mise en saillance de certains aspects interprétatifs dans le traitement médiatique, nous postulons que les catégories éditoriales se distinguent à la fois par (i) leurs priorités thématiques et (ii) leurs manières de cadrer les sujets.

H1 - Affinité éditoriale

Nous faisons alors l'hypothèse que plus un article est thématiquement atypique au sein de sa catégorie (écart thématique élevé), plus sa tonalité tend à être moins positive / plus négative. Cette attente s'appuie sur deux mécanismes complémentaires : (i) lorsque le sujet est « dans la zone de confort » éditoriale, les routines, sources et cadres interprétatifs sont plus stabilisés, ce qui peut produire des traitements plus maîtrisés ; (ii) à l'inverse, l'actualité traitée hors du cœur éditorial peut mobiliser davantage de cadrages de conflit, de prudence ou de distance, et la littérature sur les *news values* rappelle la centralité de la négativité dans la sélection et la mise en récit de l'information (Shoemaker & Reese, 2014; Tuchman, 1978).

2. Méthodologie

Le fichier *corpus_work_pubpresse* constitue le cœur du matériau textuel mobilisé dans ce projet. Il regroupe 5 821 articles publicitaires issus de 294 titres de presse française, couvrant la période 2010-2025, correspondant à l'année de publication. Chaque entrée correspond à un article et comporte des métadonnées essentielles : identifiant, titre, auteurs, média d'origine, langue et informations de source. La colonne '*text*' contient le contenu intégral de l'article. Enfin, la variable 'type' indique la catégorie éditoriale de la source (Générale, Pro, Ecofinance). L'ensemble forme une base structurée et suffisamment riche pour analyser, via des méthodes computationnelles, la diversité des discours journalistiques.

La première étape consiste à classifier les médias présents dans le corpus selon une typologie éditoriale plus précise que celle initialement fournie. Les catégories d'origine, trop larges, ne permettaient pas une analyse suffisamment fine. Nous avons donc défini une nouvelle organisation éditoriale comprenant les catégories Généraliste, Économique, Politique/Société, Culture/Arts, Sport, Tech/Science, Santé, Pro/Sectoriel et Lifestyle. Cette classification, réalisée à l'aide d'un LLM, permet de structurer le corpus et d'identifier les logiques éditoriales propres à chaque famille de presse (*Fig. 1*).

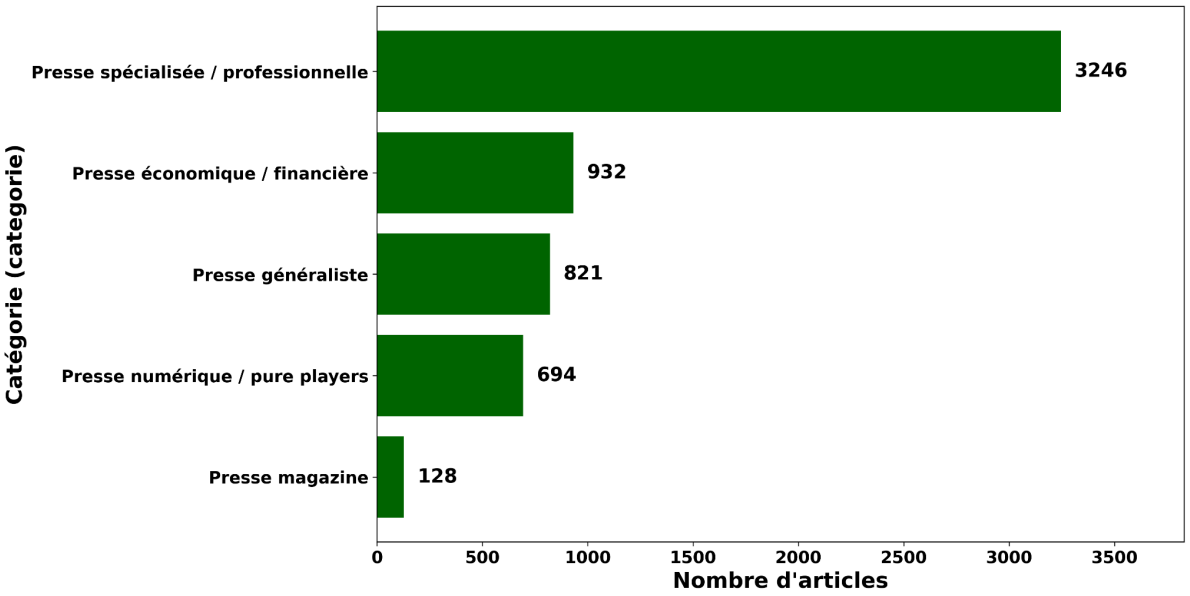

Figure 1 : Classification des articles par catégories de presse

Nous avons par la suite appliqué une chaîne de traitement standard de modélisation thématique afin d'extraire, à partir du texte intégral des articles, une représentation probabiliste des thèmes abordés. Dans un premier temps, l'ensemble des contenus a été nettoyé et normalisé : les textes ont été convertis en minuscules, les URL et caractères non alphabétiques ont été supprimés, puis une liste de stop words français (NLTK) a été appliquée. Conformément aux objectifs de l'étude, nous avons également retiré explicitement les tokens liés à la publicité (p. ex. *pub*, *publicité*, *publicitaire*), afin d'éviter que des éléments non éditoriaux ou des artefacts de mise en page n'influencent la structure thématique.

Les textes prétraités ont ensuite été vectorisés à l'aide d'une représentation sac-de-mots (bag-of-words) basée sur des comptages, en incluant des unigrammes et bigrammes afin de mieux capter des expressions multi-mots fréquentes dans la presse (p. ex. « transformation numérique », « intelligence artificielle »). Pour réduire l'impact des termes trop rares ou trop génériques, nous avons appliqué un filtrage de fréquence, ce qui permet d'éliminer les hapax (peu informatifs pour la structuration du corpus) et les mots très fréquents (souvent peu discriminants). Sur cette base, nous avons entraîné un modèle LDA (*Latent Dirichlet Allocation*), qui représente chaque article comme une distribution de topics et chaque topic comme une distribution de termes. Cette représentation probabiliste est particulièrement adaptée aux corpus journalistiques, où un même article combine souvent plusieurs registres thématiques.

Le choix du nombre de topics K a été opéré selon une procédure de sélection sur grille, en testant plusieurs valeurs (ici K=5 à K=21). Pour justifier ce choix de manière reproductible tout en restant centré sur l'interprétabilité, nous avons combiné deux critères complémentaires : (i) la perplexité du modèle (indicateur d'ajustement, à minimiser) et (ii) une mesure de diversité lexicale des topics (proportion de termes distincts parmi les mots les plus représentatifs de l'ensemble des topics, à maximiser), afin d'éviter des solutions redondantes ou trop fragmentées. Le K retenu correspond au meilleur compromis entre qualité d'ajustement et diversité thématique. Le nombre de topics retenu par l'algorithme est 9.

Une fois le modèle final entraîné, nous avons projeté chaque document dans l'espace des topics via la transformation LDA. Cette étape produit, pour chaque article, un vecteur de probabilités de dimension 9, où chaque composante correspond au score (entre 0 et 1) d'appartenance de l'article à un topic, et où la somme des scores est égale à 1. Ces distributions document-topic constituent la base des analyses ultérieures : (i) calcul de profils thématiques moyens par catégorie éditoriale, (ii) mesure de l'écart d'un article au profil moyen de sa catégorie via une divergence entre distributions, et (iii) exploration des liens entre atypisme thématique et tonalité. Enfin, pour faciliter l'interprétation qualitative des topics, nous avons produit pour chacun d'eux une liste de termes les plus pondérés ainsi qu'un nuage de mots (*word cloud*) construit à partir des poids terme-topic, permettant de visualiser rapidement les champs lexicaux dominants de chaque thème (*Fig. 2*).

L'inspection des termes les plus pondérés et des nuages de mots (*Fig. 2*) met en évidence neuf registres thématiques principaux, couvrant notamment (i) les grandes plateformes et services numériques (Google/Facebook/Apple), (ii) les données, cookies et la protection de la vie privée, (iii) des enjeux environnementaux (pollution, transition, déchets), (iv) l'écosystème médiatique et audiovisuel, (v) consommation/santé/alimentation et prix, (vi) droit et régulation (incluant marchés publics et codes), (vii) actualités économiques et résultats financiers, (viii) un thème plus générique/peu discriminant, et (ix) communication, marques et agences.

Figure 2 : Panel des nuages de mots par topic

Les distributions thématiques estimées par le modèle ont ensuite été agrégées par catégorie éditoriale afin de caractériser, pour chacune d'elles, une signature thématique moyenne. Concrètement, nous calculons, pour chaque catégorie, la moyenne des scores de topic sur l'ensemble des articles qui lui appartiennent. Les résultats (*Fig. 3*) mettent en évidence des profils nettement différenciés : certaines catégories présentent une forte concentration sur quelques thèmes dominants, tandis que d'autres affichent une répartition plus équilibrée entre topics, suggérant une couverture plus transversale. Cette structuration est cohérente avec l'idée que les routines de production et la spécialisation des rubriques contribuent à stabiliser, au-delà des variations de l'actualité, des "centres de gravité" thématiques propres à chaque segment de presse. Ainsi, au-delà des thèmes globaux du corpus, chaque catégorie éditoriale se caractérise par une combinaison récurrente de topics qui synthétise sa ligne éditoriale moyenne (*Fig. 3*).

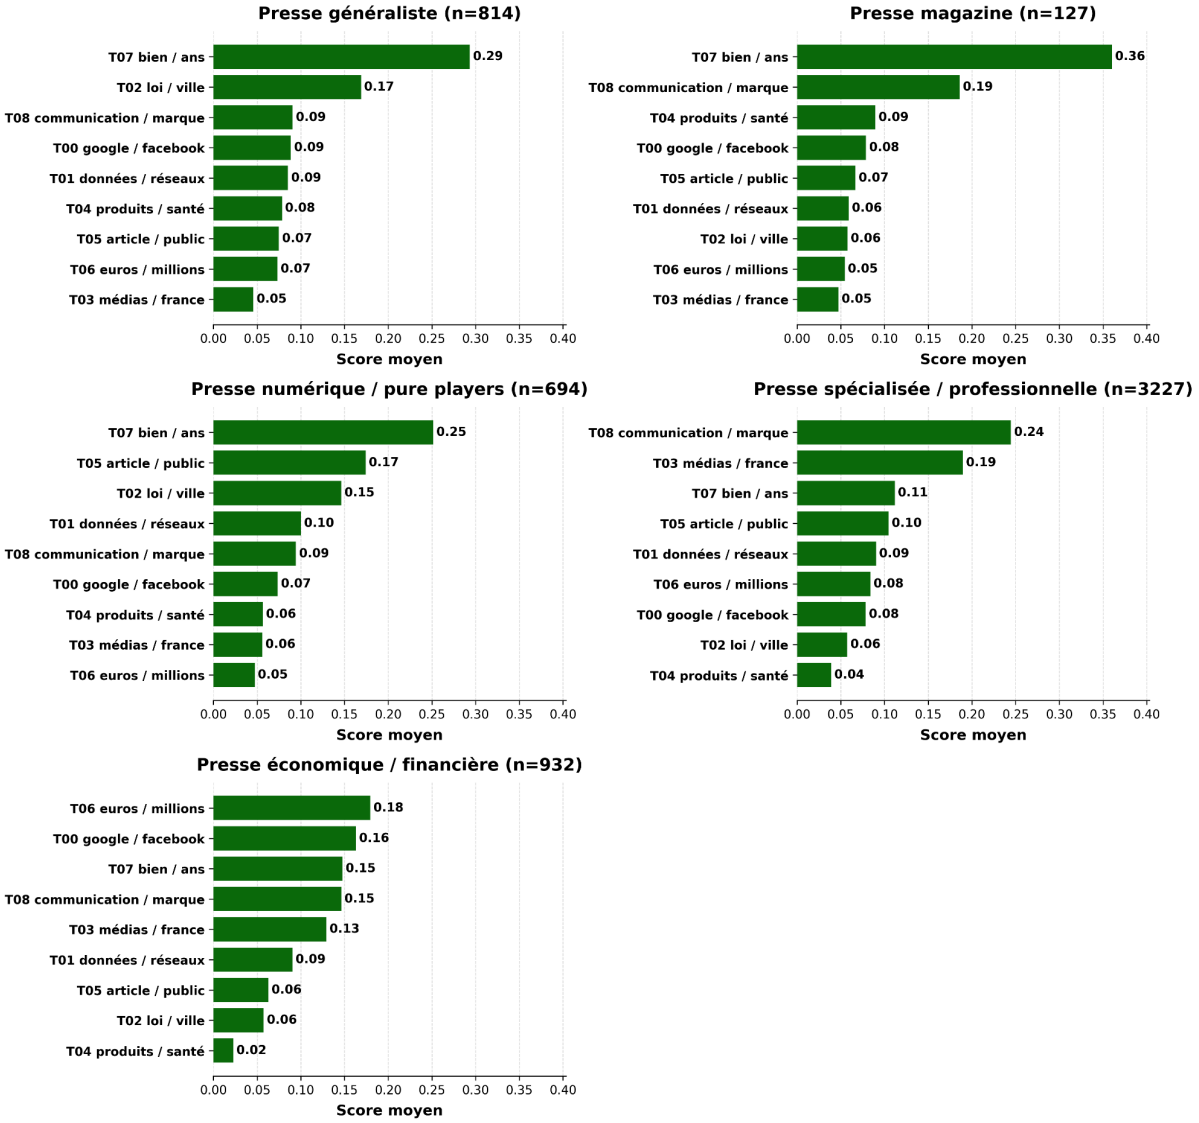

Figure 3 : Panel des scores moyens par topic en fonction de la catégorie éditoriale

À partir de ces profils moyens, nous introduisons ensuite un indicateur continu d'écart thématique à la ligne éditoriale, que nous appelons divergence éditoriale. Pour chaque article, on dispose d'un ensemble de 9 scores (un par topic, sommant à 1) et, pour la catégorie à laquelle il appartient, d'un ensemble de 9 scores moyens. La divergence éditoriale mesure alors la distance entre ces deux distributions : plus la valeur est élevée, plus l'article s'écarte de la signature thématique typique de sa catégorie, et plus il peut être interprété comme un contenu "hors-cœur éditorial" au regard des thèmes habituellement traités par ce segment de presse. Cet indicateur servira ensuite de variable explicative pour tester si le fait de traiter des thèmes plus éloignés du profil habituel s'accompagne d'une tonalité affective différente dans le texte. L'écart d'un article à la signature thématique moyenne de sa catégorie est mesuré par la distance de Jensen-Shannon, adaptée à la comparaison de distributions de probabilités et bornée, ce qui facilite l'interprétation.

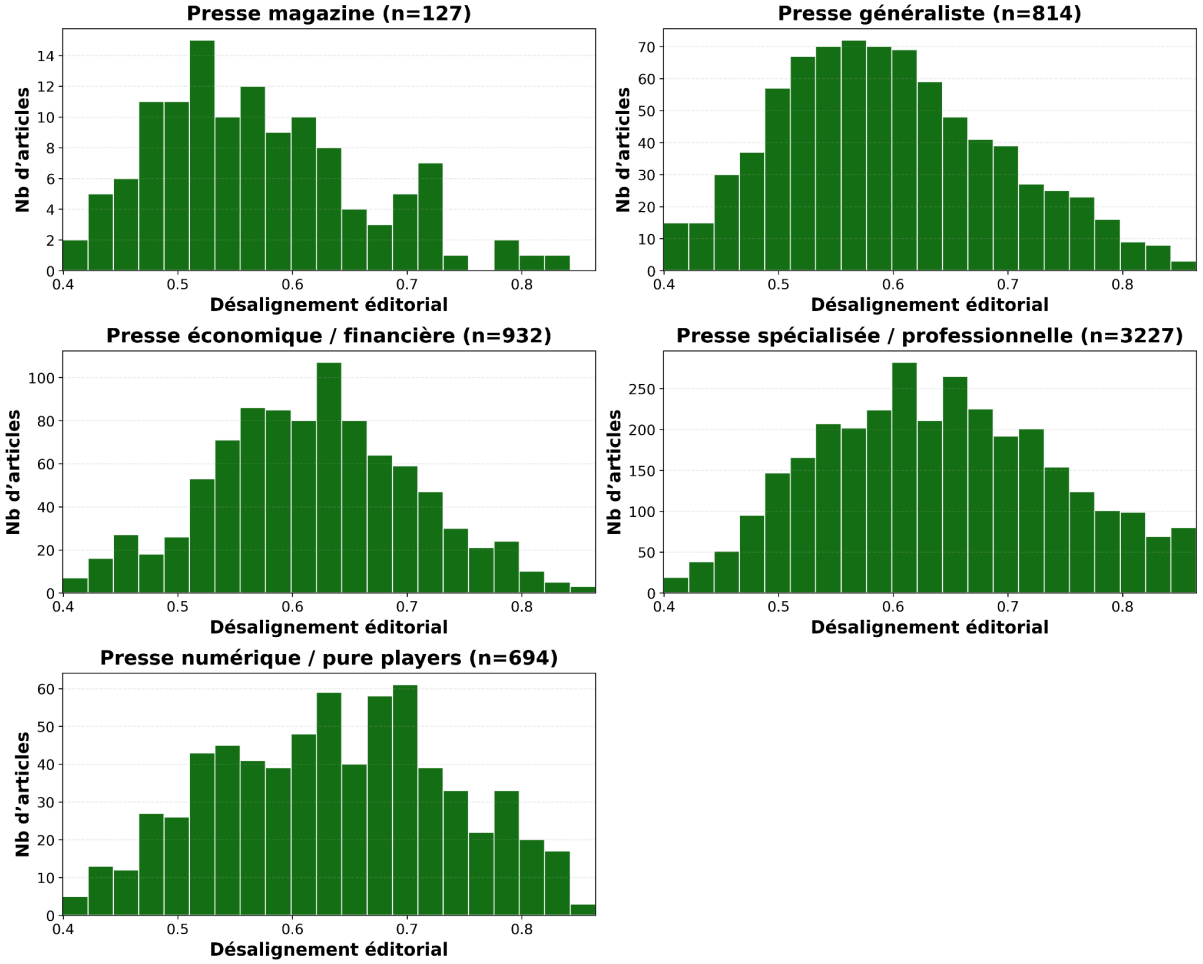

Figure 4 : Distribution du désalignement éditorial par catégorie

La Figure 4 présente la distribution du désalignement éditorial (distance de Jensen-Shannon entre la distribution de topics d'un article et la signature moyenne de sa catégorie) pour chacune des catégories de presse. Dans l'ensemble, les distributions sont centrées autour de valeurs intermédiaires,

ce qui suggère que la plupart des articles restent relativement proches du profil thématique typique de leur segment, tout en laissant apparaître une variabilité. On observe toutefois des différences entre catégories : la presse magazine semble afficher une distribution plus irrégulière, cohérente avec un effectif plus réduit et une diversité plus hétérogène des contenus, tandis que les catégories à forts volumes (presse spécialisée/professionnelle, économique/financière, généraliste) présentent des profils plus stables et lisses.

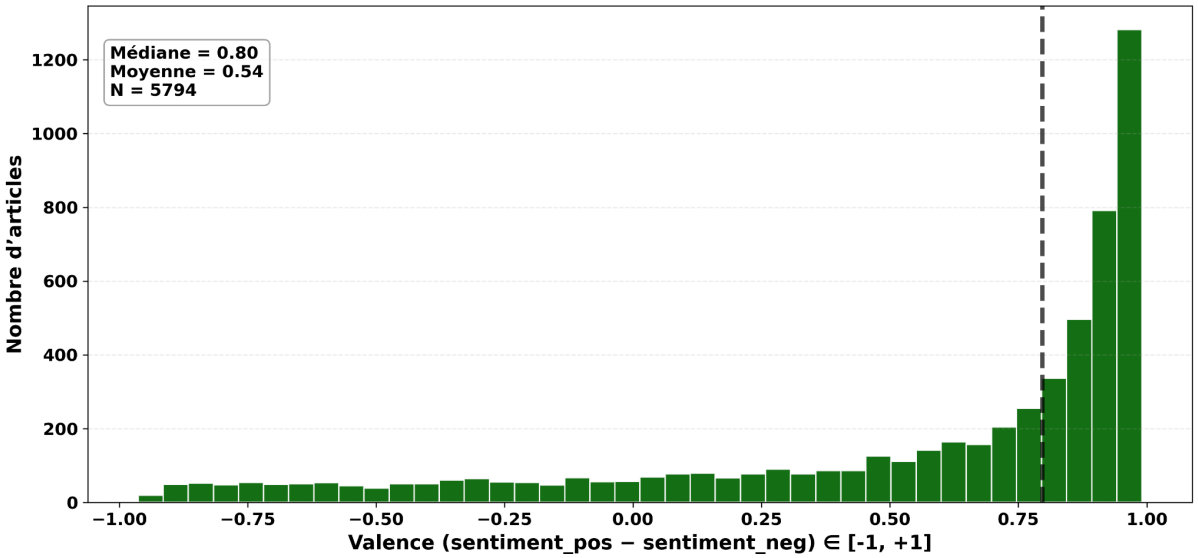

Figure 5 : Distribution des score de l'analyse de sentiments, -1 étant le plus négatif et 1 le plus positif

Afin d'estimer la tonalité affective des articles, nous avons appliqué une analyse de sentiment supervisée fondée sur un modèle de langue de type CamemBERT. Le modèle renvoie, pour chaque texte d'article, une distribution de probabilités sur les deux classes ; nous retenons alors deux scores continus, sentiment_pos = P(POSITIF) et sentiment_neg = P(NEGATIF), tels que leur somme vaut 1. À partir de ces probabilités, nous construisons un indicateur synthétique de valence défini comme *valence = sentiment_pos − sentiment_neg*, borné entre -1 (tonalité très négative) et +1 (tonalité très positive), avec 0 correspondant à une polarité neutre (probabilités équilibrées).

La distribution de la valence (*Fig. 5*) met en évidence une tonalité globalement orientée vers le positif dans le corpus : la plupart des articles se situent du côté des valeurs positives, avec une concentration marquée aux niveaux élevés. L'usage d'un score continu permet de mobiliser la valence comme variable quantitative dans les analyses statistiques à venir, notamment pour tester l'hypothèse d'un lien entre désalignement éditorial (divergence thématique intra-catégorie) et tonalité des articles.

3. Résultats Statistiques

Pour tester H1, nous avons adopté une stratégie en deux volets. D'abord, nous estimons une corrélation de Spearman entre la divergence éditoriale (distance de Jensen-Shannon) et la valence (sentiment_pos − sentiment_neg) afin d'évaluer l'existence d'une relation monotone, sans hypothèse forte sur la linéarité. Ensuite, nous estimons un modèle de régression linéaire où la valence est expliquée par la divergence. Compte tenu de l'hétérogénéité possible entre segments de presse, ces deux tests sont réalisés séparément pour chaque catégorie éditoriale, ce qui permet d'identifier des effets potentiellement contrastés (ou de signe opposé) qu'un modèle global pourrait masquer.

Catégorie	**Spearman ρ**	**p (Spearman)**	**OLS β (divergence vs valence)**	**p (OLS)**
Presse généraliste	+0.070	0.046	+0.369	0.079
Presse magazine	−0.071	0.427	−0.162	0.726
Presse numérique / pure players	+0.176	< 0.001	+0.808	< 0.001
Presse spécialisée / professionnelle	−0.183	< 0.001	−0.403	< 0.001
Presse économique / financière	−0.093	0.005	−0.388	0.058

Figure 6 : Tableau des tests statistiques de H1

Les résultats révèlent une forte variation selon les segments. La relation attendue par H1 apparaît clairement dans la presse spécialisée/professionnelle, où une divergence plus élevée est associée à une valence plus faible (Spearman $\rho = -0.183$, $p < 0.001$; OLS $\beta = -0.403$, $p < 0.001$). Un signal cohérent mais plus modéré est observé pour la presse économique/financière, avec une corrélation négative et une pente OLS négative à la limite de la significativité (Spearman $\rho = -0.093$, $p = 0.005$; OLS $\beta = -0.388$, $p = 0.058$). En revanche, la presse numérique/pure players montre une relation de signe opposé : les articles les plus divergents tendent à être plus positifs (Spearman ρ =

+0.176, $p < 0.001$; OLS $\beta = +0.808$, $p < 0.001$). La presse généraliste présente aussi une association légèrement positive (Spearman $\rho = +0.070$, $p = 0.046$; OLS $\beta = +0.369$, $p = 0.079$), tandis que la presse magazine ne montre pas de relation détectable (Spearman $\rho = -0.071$, $p = 0.427$; OLS $\beta = -0.162$, $p = 0.726$). Globalement, ces résultats suggèrent que l'"affinité éditoriale" est surtout visible dans les segments les plus spécialisés, alors que, dans des segments plus transversaux, l'écart thématique ne s'accompagne pas nécessairement d'un ton plus négatif.

4. Conclusion

En combinant modélisation thématique et analyse de sentiment, ce travail met en évidence deux résultats principaux. D'une part, les catégories éditoriales se distinguent par des signatures thématiques moyennes propres, ce qui suggère des régularités liées aux routines de production et à la spécialisation. D'autre part, la construction d'un indicateur continu de divergence éditoriale permet de quantifier, au niveau de chaque article, l'écart à la ligne thématique typique de sa catégorie et d'examiner comment cet "hors-cœur" thématique s'articule avec la tonalité affective des textes. Nos résultats montrent toutefois que cette relation n'est pas uniforme selon les segments : l'association attendue par l'hypothèse d'affinité éditoriale apparaît surtout dans les catégories les plus spécialisées (en particulier la presse spécialisée/professionnelle, et plus modestement la presse économique/financière), où les articles les plus divergents tendent à adopter une tonalité moins positive. Une interprétation possible est que, dans ces segments, le "hors-cœur" thématique correspond plus fréquemment à des contenus traitant de controverses, de risques, de régulations ou de dysfonctionnements, autrement dit, des sujets où l'écriture vise davantage à documenter des problèmes, soulever des enjeux ou mettre en discussion des effets indésirables, ce qui se traduit par une valence plus négative.

À l'inverse, dans la presse numérique/pure players (et, dans une moindre mesure, dans la presse généraliste), la divergence est associée à une tonalité plus positive. Cela peut indiquer que la thématique atypique y renvoie moins à des "incidents" ou à des cadrages de conflit qu'à une logique de diversification (décalages de rubrique, formats plus narratifs ou "service", mise en avant d'innovations, portraits, tendances), où sortir du cœur thématique peut au contraire s'accompagner d'un registre plus valorisant. Ces contrastes invitent à considérer la divergence éditoriale non seulement comme une mesure d'écart thématique, mais aussi comme un signal de changement de genre ou de fonction journalistique selon les segments (enquête/problématisation vs. découverte/valorisation).

Plusieurs limites doivent toutefois être soulignées. Les topics issus du LDA restent sensibles aux choix de prétraitement et au paramétrage, et la mesure de tonalité dépend des performances et des biais du modèle de sentiment (domaine d'entraînement, sensibilité au lexique évaluatif, troncature du texte). Par ailleurs, l'analyse met en évidence une association mais ne permet pas, à elle seule, d'isoler des mécanismes causaux : les variations observées peuvent aussi refléter des différences de genre journalistique, d'événements traités ou de styles propres aux médias.

Ces résultats ouvrent plusieurs pistes. Une extension naturelle consisterait à tester la robustesse avec d'autres approches thématiques (p. ex. BERTopic/CTM), à enrichir la dimension discursive (émotions, cadrages, subjectivité), et à intégrer des modèles plus fins tenant compte des effets propres aux médias et des dynamiques temporelles. Cela permettrait de mieux comprendre

comment les lignes éditoriales se maintiennent, se déplacent ou se reconfigurent lorsque les médias abordent des thèmes plus ou moins éloignés de leur “zone de confort”.

5. Bibliographie

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). *Latent Dirichlet Allocation*. *Journal of Machine Learning Research, 3*, 993–1022.

Entman, R. M. (1993). *Framing: Toward Clarification of a Fractured Paradigm*. *Journal of Communication, 43*(4), 51–58.

Fishman, M. (1980). *Manufacturing the News*. University of Texas Press.

Harcup, T., & O’Neill, D. (2001). *What is news? Galtung and Ruge revisited*. *Journalism Studies, 2*(2), 261–280. https://doi.org/10.1080/14616700118449

Korenčić, D., Ristov, S., & Šnajder, J. (2015). *Getting the agenda right: Measuring media agenda using topic models*. In *Proc Models: Post-Processing and Applications Workshop (TM@CIKM 2015)* (pp. 61–66).

McCombs, M. E., & Shaw, D. L. (1972). *The agenda-setting function of mass media*. *Public Opinion Quarterly, 36*(2), 176–187.

Shoemaker, P. J., & Reese, S. D. (2014). *Mediating the Message in the 21st Century: A Media Sociology Perspective*. Routledge.
What is news Original

Tuchman, G. (1978). *Making News: A Study in the Construction of Reality*.